

ESASR

Evidence-State Adaptive Scholarly Retrieval

技术迭代与问题解决记录

第八届中国研究生人工智能创新大赛附加材料

团队名称：Justifying

提交日期：2026 年 8 月 31 日

目录

1	文档定位与阅读方式	1
2	技术演进总览	1
3	检索排序方案的收敛过程	2
3.1	V1: 标题偏置词法召回	2
3.2	V2: 标题与摘要等权	2
3.3	V3: 局部 Cross Encoder 精排	2
3.4	多路 RRF 融合的对照分析	2
3.5	V5: 自适应结果集	3
4	技术瓶颈与问题解决闭环	4
5	关键参数与选择依据	5
6	复现实验与资产索引	5
7	扩展验证计划与实验契约	5
8	审计结语	6

1 文档定位与阅读方式

本材料是项目主报告的过程审计层，集中记录架构探索、模块替换、参数选择、对照结论、工程改进与验证闭环。主报告只叙述最终提交方案“证据状态驱动的自适应学术检索框架 (ESASR)”；本材料保留从早期原型到最终方案的完整技术债务和证据链。两份文档的分工如下：

表 1 主报告与附加材料的内容边界

材料	回答的问题	内容
项目主报告	最终方案是什么、为何合理、证据有多强	单一方法主线、核心实验、系统完成度、应用与边界
本附加材料	如何收敛到最终方案、如何识别改进空间、如何复现	迭代时间线、详细消融、对照结论、改进闭环、参数与归档位置

为避免事后合理化，本记录坚持三条原则：第一，正向结果与对照结论同时保留；第二，代码实现、实验验证和强效果结论分级标记；第三，任何未在冻结协议下验证的机制均列为待验证，不因其架构完整而推断质量收益。

2 技术演进总览




图 1 以可证伪实验收敛最终方案。标题权重、语义精排、RRF 路由和自适应输出均在相同数据或冻结候选条件下比较；未带来收益的方案不进入最终主线。

表 2 项目与文档演进记录

标识	日期	主要变化	形成的可审计产物
v0.1	2026.05.22	完成赛题拆解、用户需求与验收口径定义	需求清单、范围边界与项目文档基线
v0.2	2026.06.12	完成总体架构、数据流和外部接口设计	架构图、接口规范与研发计划
v0.3	2026.07.10	完成查询编译、缺口路由、多源检索与排序链路	可运行端到端原型、模块接口与测试样例
v0.4	2026.08.08	冻结数据划分、基线、消融和输出策略评测协议	实验脚本、候选集、指标、区间与错误分析
v0.5	2026.08.26	完成系统集成、回归测试、故障处理和材料一致性校验	稳定演示系统、测试记录与候选提交材料
v1.0	2026.08.31	完成版本冻结、复现入口复核和最终提交定版	最终报告、附加材料、代码仓库与演示资产

3 检索排序方案的收敛过程

3.1 V1：标题偏置词法召回

早期本地检索使用 SQLite FTS5，标题权重 5、摘要权重 1。其动机是题名通常浓缩论文主题，但该设置放大了查询词表面重合，导致“标题像答案、摘要语义不匹配”的候选占据首位。在固定 200 条样本上， $P@1$ 为 0.2250、 $R@1$ 为 0.1745、 $\text{Macro F1}@1$ 仅 0.1862。问题定位并非召回数量不足，而是标题信号压倒摘要证据。

3.2 V2：标题与摘要等权

将标题和摘要权重均设为 1 后， $P@1$ 提升至 0.3000， $\text{Macro F1}@1$ 提升至 0.2466，绝对增量 0.0604。该结果说明最有效的早期改动不是引入复杂网络，而是纠正已有特征的权重失衡。这一事实被保留在主报告消融中，用于防止把所有收益归因于 Cross Encoder。

3.3 V3：局部 Cross Encoder 精排

在相同 Top-100 候选池内，本地 cross-encoder/ms-marco-MiniLM-L6-v2 仅重排 Top-20，并按 0.65 语义分数与 0.35 基础分数融合。 $\text{Macro F1}@1$ 达到 0.2649，较 V2 增加 0.0183；平均端到端延时 741.7 ms，平均精排耗时 285.3 ms。配对差值区间跨越 0，因此该模块被判断为“方向合理、工程可用、统计证据仍不足”。

3.4 多路 RRF 融合的对照分析

多路检索和 RRF 的理论预期是提高不同表达的覆盖，但在相同 200 条样本上 $F1@1$ 为 0.2562，低于单路局部精排方案的 0.2649，平均延时也升至 905.0 ms。可能原因包括：本地语料上的各路

词法结果高度相关，RRF 增加的不是互补证据而是重复噪声；融合顺序改变了 Cross Encoder 候选池；当前查询样本对路由多样性的需求不足。该结果清晰界定了多路融合的适用条件，并为最终采用更高效的候选组织方式提供了直接实验依据。

3.5 V5：自适应结果集

固定 Top-1 在多答案查询上可能丢失相关论文，但固定扩大 K 又迅速增加误报。为隔离“检索排序”与“输出数量”的影响，V5 直接读取冻结候选，不重新召回或精排。200 条查询按来源拆为 100 条开发集和 100 条测试集；开发集搜索 8,064 组阈值组合，测试集只使用最终规则。CARS 测试 F1 为 0.2571，固定 Top-1 为 0.2475，平均仅多返回 0.07 篇。由于配对区间包含 0，最终报告将其写为小幅正向趋势。




图 2 各中间方案的量化比较。左图记录排序方案收敛，右图记录固定 Top-K 与 CARS 的输出策略对照。

表 3 V1–V4 固定样本比较 ($n = 200$)

方案	关键配置	P@1	R@1	F1@1	F1 95% CI
V1	标题 5、摘要 1	0.2250	0.1745	0.1862	[0.1377, 0.2371]
V2	标题 1、摘要 1	0.3000	0.2301	0.2466	[0.1928, 0.3015]
V3	V2 + CE Top-20	0.3300	0.2454	0.2649	[0.2092, 0.3226]
V4	多路 RRF + CE Top-20	0.3200	0.2389	0.2562	[0.1982, 0.3132]

表 4 V5 独立测试集详细对照 ($n = 100$)

策略	P	R	F1	F1 95% CI	平均返回数
Top-1	0.3300	0.2241	0.2475	[0.1715, 0.3255]	1.00
Top-2	0.1900	0.2537	0.1986	[0.1424, 0.2537]	2.00
Top-3	0.1400	0.2697	0.1665	[0.1219, 0.2105]	3.00
Top-5	0.0960	0.2926	0.1304	[0.0991, 0.1627]	5.00
CARS	0.3350	0.2374	0.2571	[0.1812, 0.3350]	1.07

4 技术瓶颈与问题解决闭环

表 5 核心技术问题、定位、修复与验证

编号	改进目标	原因分析	解决方案与验证	状态
P01	标题相似但任务不相关的论文居首	标题权重过高，摘要证据被压制	标题摘要等权；F1 从 0.1862 升至 0.2466	已闭环
P02	词法召回无法识别语义等价表达	仅依赖词项匹配	Top-20 本地 Cross Encoder；真实案例将 LoFTR 提升至首位	已闭环
P03	识别多路融合的适用条件	各路候选高度相关并带入重复噪声	保留对照结果，默认不采用该路由；后续开展跨域验证	对照结论
P04	优化固定 Top-K 的误报问题	多答案召回收益小于误报损失	CARS 仅在三门同时满足时增加第二篇	已验证趋势
P05	缺失年份/摘要/DOI 被默认值掩盖	展示逻辑把“未知”当成“有值”	保持 null，增加 metadataMissing 并回归测试	已闭环
P06	外部失败时演示论文可能污染真实结果	严格检索与兼容展示边界不清	完整检索传播失败；离线卡片统一来源标识	已闭环
P07	related works 被误画为引用边	不同关系共享一个边类型	分离有向 CITES 与无向 RELATED	已闭环
P08	保证无模型平台 Key 时仍可检索	规划与远端模型强绑定	增加确定性规则规划器与统一输出模式	已闭环
P09	健康端点可达但依赖已失效	只检查 HTTP 可达性	聚合组件状态，异常返回 503/degraded	已闭环
P10	导出链接可能指向错误页面	DOI、来源 URL 与 PDF URL 混用	按 DOI/来源映射，PDF 仅使用有效 OA 地址	已闭环
P11	进一步降低前端首包体积	Element Plus、ECharts、G6 同步打包	已确认构建可用；按需引入与拆包已纳入计划	已规划
P12	扩展在线补检增益证据	本地静态语料不包含真实 API 漂移与引文图	已设计冻结响应、等预算三组对照协议	协议已设计

5 关键参数与选择依据

表 6 最终提交配置及证据依据

参数	取值	依据与边界
词法标题/摘要权重	1/1	固定 200 条样本显著优于 5/1；仍需跨语料敏感性分析
候选池	Top-100	保留排序诊断与可复现候选；不是最终输出规模
Cross Encoder 范围	Top-20	在当前 CPU 环境兼顾语义收益与 285.3 ms 平均推理耗时
最终融合权重	0.65/0.35	当前实验配置；未宣称理论最优
子查询上限	4	控制计划扩张；两来源对应最多 8 个逻辑任务
CARS 最大输出	2	开发集搜索后选定，避免固定扩展造成误报
CARS 三门阈值	0.60/0.85/0.10	仅由 100 条开发集选择，测试集不参与调参
bootstrap 次数	主评测 1,000； 配对 5,000	用于区间估计；样本不足仍会导致宽区间

6 复现实验与资产索引

排序实验归档于 `esasr-api/evaluation/experiments/` 下的 ScholarGym 离线目录，包含 Gold、逐查询预测、指标、排行榜、比较报告和 manifest。自适应选择目录包含开发/测试 Gold、固定 K 预测、CARS 预测、阈值搜索与配对结果。复现时应先记录代码提交、Python/Node 依赖、模型名称与 revision、随机种子、数据文件哈希和配置哈希，再运行评测脚本；不得只保留汇总表而丢失逐查询记录。

建议的验收顺序为：运行后端 63 项与 CLI 9 项测试；执行前端生产构建；复跑排序实验并核对 $F1@1=0.2649$ 、平均时延 741.7 ms；复跑一至两篇的受控自适应输出实验并核对 CARS $F1=0.2571$ 、平均返回数 1.07；使用 DeepSeek-V4-Flash-0731 绕过规划缓存复跑 30 条在线样本，并核对 API usage 总 Token 为 24,840；再验证五档置信质量动态截断的近似并列保留、80% 质量覆盖和广泛档相关性边界；启动容器服务并检查 503/degraded 语义；模拟无模型平台 Key、精排不可用和学术 API 异常；最后核对来源、缺失字段和关系分型。

所有新绘学术图片均位于项目根目录 `/images`，使用“图序号_方法名_用途”命名，并同时保留 PNG、SVG 与 PDF。PNG 用于主报告稳定编译，SVG 用于后续编辑，PDF 用于字形与矢量质量审计。

7 扩展验证计划与实验契约

1. 在线 EGRR 效果：冻结 API 响应，设置无补检、固定二轮、缺口驱动三组，在相同任务上限下报告 F1、覆盖率、HTTP 尝试和单位真阳性成本。
2. 查询编译准确率：建立按主题、方法、数据集、年份、Venue、开放获取和排除条件分层的人工标注集，报告槽位 F1 与硬约束违反率。

3. **CARS 外部有效性**：在更大跨学科测试集上预注册当前阈值，不重新调参，报告配对区间和按 Gold 规模分组的收益。
4. **系统压力与恢复**：在固定硬件上报告并发 1/5/20 的 p50/p95 时延、错误率、缓存命中率和依赖恢复时间。
5. **真实应用验证**：开展跨学科高校课题组测试，记录任务完成时间、有效论文率、重复检索率、结果修正次数和来源核验行为。

只有当相应实验完成并得到冻结证据后，机制才可从“已实现”升级为“已证实有效”。若结果为负，应继续保留原始数据和分析，而不是从提交材料中删除。

8 审计结语

项目最终方案不是按时间顺序累积全部尝试，而是由受控实验筛选得到：等权词法修复了明显偏置，局部精排提供语义增益，多路 RRF 经对照验证后退出默认路径，CARS 在冻结候选上以极小输出扩张取得初步正向结果。可信数据边界与故障传播则把“能运行”提升为“结果可追责”。后续将优先扩大独立测试规模，完成在线等预算消融与真实用户验证，使当前的可运行、可追责优势进一步转化为跨领域的稳定效果。