

第八届中国研究生人工智能创新大赛

ESASR

证据状态驱动的自适应学术检索框架

Evidence-State Adaptive Scholarly Retrieval

项目报告

团队名称: **Justifying**

参赛组别: 企业赛题组

提交日期: **2026 年 8 月 31 日**

目录

摘要	1
1 项目概况	2
1.1 背景和基础	2
1.2 场景和价值	2
1.3 所需支持	3
2 项目规划	6
2.1 整体目标	6
2.2 技术创新点	6
3 实施方案	11
3.1 技术可行性分析	11
3.2 技术细节	11
3.3 实验设计与结果	13
3.4 作品完整性与展示闭环	17
3.5 应用价值与科研服务前景	19
3.6 可靠性保障与扩展验证	20
3.7 计划与分工	21
4 参考资料	23

文档修订记录

序号	更改原因	版本	修订人	更改日期	备 注
1	需求分析与范围界定	v0.1	队长	2026.05.22	形成需求与验收基线
2	总体架构与接口设计	v0.2	队员 B	2026.06.12	数据流 和接口规范
3	核心检索模块开发	v0.3	队员 A	2026.07.10	查询编译 与多源检索
4	基线消融与实验验证	v0.4	队长	2026.08.08	数据划分 和评测协议
5	系统集成与材料完善	v0.5	队员 B	2026.08.26	联调回归 与材料校验
6	最终提交定版	v1.0	队长	2026.08.31	最后审阅与 微修文档叙述

摘要

复杂科研查询往往同时包含主题、方法、数据集、时间、发表平台、开放获取和排除条件，传统关键词检索依赖反复试词，通用大模型则可能遗漏约束、缺少可核验来源并产生不稳定调用成本。本项目将其定义为预算约束下的证据集合构建问题：系统根据当前证据状态联合判断约束满足程度、是否继续检索以及结果集规模。

项目提出证据状态驱动的自适应学术检索框架（Evidence-State Adaptive Scholarly Retrieval, ESASR）。框架以约束感知查询编译、证据缺口驱动多源检索、证据融合排序、Cross Encoder 局部精排与置信度门控动态截断构成统一决策闭环；OpenAlex 与 Semantic Scholar 提供可核验候选，排序质量、绝对与相对相关性及相邻分数落差共同决定返回范围。相较固定轮次和固定 Top-K，ESASR 使检索深度与结果规模均具有可解释状态依据。

排序模块实验从 2,536 条查询中分层抽取 200 条，在 570,206 篇论文的 ScholarGym 冻结镜像上评测。等权词法召回的 Top-1 Macro F1 为 0.2466；引入 Cross Encoder 精排后提升至 **0.2649**，相对增益约为 7.42%。在输出策略实验中，同一批冻结候选进一步划分为 100 条开发查询和 100 条独立测试查询：开发集仅用于确定自适应截断参数，测试集用于最终评价。自适应输出策略在测试集上的 Macro F1 为 **0.2571**，高于固定 Top-1 的 0.2475，平均每条查询返回 1.07 篇论文。在线效率评测从 ScholarGym 的三个查询来源中分层抽取 30 条有效查询，关闭规划缓存，并使用 DeepSeek-V4-Flash-0731（默认思考模式）通过真实 API 执行查询规划，同时接入 OpenAlex 与 Semantic Scholar 完成在线检索。Token 消耗直接读取模型 API 返回的 usage 字段，解析失败与重试产生的消耗均计入统计。30 条查询中，22 条进入模型规划，8 条由确定性规则完成；总消耗为 **24,840 Token**，按全部查询计算平均为 **828 Token/条**。检索阶段共执行 166 次逻辑检索调用，平均为 5.53 次/条，未超过每条查询 8 次的预算上限。

工程系统基于 Vue 3、FastAPI、PostgreSQL、Redis、Neo4j 与 Docker Compose 构建，形成从复杂查询输入、多源候选组织到证据化结果输出的完整运行闭环。系统提供五档风险—覆盖策略，根据候选分数质量与相邻落差动态确定结果集规模；输出内容包括论文列表、约束覆盖摘要、检索轨迹和论文关系图，并完整保留数据来源、缺失字段、约束命中及异常状态。后端自动化测试、CLI 测试、前端类型检查与生产构建均已通过。在 MacBook Air（Apple M3，macOS 26.6.2）上开展的 200 条离线查询评测中，冻结候选条件下排序链路的每查询平均处理时延为 **741.7 ms**，其中 Cross Encoder 精排平均耗时为 285.3 ms。上述结果验证了 ESASR 的系统可运行性、过程可审计性和实验可复现性。

关键词：学术文献检索；证据状态决策；约束感知查询；证据缺口；多源融合；交叉编码精排；自适应结果集

1 项目概况

1.1 背景和基础

在选题论证、开题调研和相关工作梳理等科研任务中，研究者通常需要从海量文献中定位同时满足主题、方法、数据集、时间范围、发表平台及排除条件的论文集合。此类检索并非简单的关键词匹配，而是涉及研究意图理解、复合约束解析、子查询分解、多源迭代检索、候选质量控制、细粒度相关性排序及结果结构化组织等连续决策。现有关键词检索系统难以完整表达复杂约束，基于大语言模型的搜索方法虽然提升了语义理解和查询规划能力，但仍面临约束遗漏、检索覆盖率与精确率失衡、结果权威性与多样性难以兼顾，以及 API 调用与 Token 成本不稳定等问题。因此，复杂学术查询需要一种能够根据当前证据状态动态调整检索策略、控制资源预算并输出可核验论文集合的端到端方法。

复杂学术检索的核心矛盾并非关键词不足，而是复合研究意图难以稳定映射为可核验的论文集合。以“寻找 2021 年以后使用 Transformer 改善低纹理区域半稠密匹配、并发表于计算机视觉主会的开放获取论文”为例，主题、方法、困难场景、时间、Venue 与开放获取条件同时存在，任一约束遗漏都会造成“语义相关但任务不可用”。针对这一难点，ESASR 将自然语言意图编译为可计算约束，并以候选证据状态控制检索、排序和停止决策，使检索目标由模糊的文本相似性转化为可审计的约束满足问题。

传统检索通常将相关性、约束满足与资源开销分开处理，因而难以解释“为何继续检索”或“为何在此处截断”。ESASR 将查询形式化为 $q = (I, H, B)$ ： I 表示主题、方法和数据集等软意图， H 表示年份、排除词和强制 Venue 等硬约束， B 表示检索任务、模型推理与时延预算。给定多源候选集合 D ，系统选择规模可变的论文集合 S_q ，在硬约束成立的条件下联合优化集合质量与调用成本：

$$\max_{S_q \subseteq D} F_1(S_q, G_q) - \lambda_1 C_{\text{api}} - \lambda_2 C_{\text{token}} - \lambda_3 C_{\text{latency}}, \quad (1)$$

其中， G_q 表示评测数据集中为查询 q 标注的相关论文集合， S_q 表示系统返回的论文集合。该目标函数将候选检索、继续检索决策和结果规模选择统一为预算约束下的证据集合优化问题；相较固定检索轮次和固定 Top-K，其能够在同一框架下刻画集合质量、资源消耗与停止条件，并为后续模块设计和等预算对照实验提供统一的形式化依据。

1.2 场景和价值

科研选题、开题调研、相关工作 (Related Work) 梳理与跨学科研究通常需要同时处理主题、方法、数据集、时间范围、发表平台、开放获取及排除条件。传统关键词检索难以完整表达这些复合约束，研究者往往需要在多个平台之间反复修改检索词、人工去重并逐篇核验来源，不仅增加检索成本，也使查询过程和结果筛选依据难以复现。尤其在跨学科场景中，同义术语、元数据缺失和平台排序差异还会进一步放大漏检与误检风险。

针对上述问题，ESASR 将复杂学术检索定义为预算约束下的证据集合构建过程。系统首先将自然语言查询转换为结构化约束，区分必须满足的硬条件与用于判断相

关性的软证据；随后通过 OpenAlex 与 Semantic Scholar 进行多源召回，并利用 DOI、来源标识和规范化标题完成跨源去重与证据合并。在候选组织阶段，系统根据当前证据缺口决定是否继续检索，通过多源证据融合与局部语义精排改善候选排序，并依据排序质量和相邻分数落差动态确定最终结果集规模。由此，问题拆解、跨源检索、候选去重、来源核验、结果排序和关系整理被组织为可追踪的统一闭环。

ESASR 的不是替代研究者作出学术判断，而是承担约束解析、跨源查找、重复记录合并、证据状态诊断和结果结构化等可程序化环节。系统完整保留查询计划、约束命中、未覆盖条件、数据来源、缺失字段、调用成本与异常状态，使研究者能够核验论文为何被检索、排序或排除。该能力适用于研究方向初筛、开题文献调研、相关工作补全、跨学科证据检索及课题组文献整理，有助于将研究者的注意力从反复试词和来源核对转移到论文阅读、证据判断与研究决策。当前实验主要验证了排序质量、输出策略和工程可运行性；系统能否进一步缩短真实用户的文献调研时间，仍需通过配对用户实验进行量化评估。

表 1 用户痛点、系统响应与验收证据

用户痛点	系统响应	验收证据
复合查询约束容易遗漏	将主题、方法、数据集、时间、Venue、开放获取和排除条件编译为统一约束模式	查询计划、硬约束、软证据及未覆盖条件可见
跨平台结果重复且排序不一致	基于 DOI、来源 ID 和规范化标题执行跨源去重，并融合多源排序证据	原始来源、规范化标识、命中子查询及融合分量可追踪
固定检索轮次造成预算浪费或证据不足	根据候选证据缺口和剩余预算决定是否触发定向补检	缺口状态、补检原因、逻辑调用次数、HTTP 尝试、Token 与时延可记录
固定 Top-K 难以兼顾精确率与召回率	根据候选质量、相对首位得分和相邻分数落差动态确定结果集规模	独立测试集上的受控策略对照及五档策略自动化测试
模型生成结果来源难以核验	返回学术数据源中的真实论文记录，不使用生成式论文条目替代检索结果	来源、DOI、开放获取状态、缺失字段和外部接口异常显式呈现
检索结果难以复用和沉淀	以论文列表、约束摘要、检索轨迹、详情页和关系图组织检索证据	查询状态可恢复，论文可进入收藏或课题库，关系类型可区分

1.3 所需支持

ESASR 已具备本地部署和基本检索能力：系统接入 OpenAlex 或 Semantic Scholar 中至少一种学术搜索 API 即可完成论文召回，在未配置大语言模型服务时，也可由确定性规则规划器完成基础查询编译。为进一步开展大规模在线评测、跨学科泛化验证和真实用户测试，项目仍需要学术数据服务、评测数据和运行环境三方面支持。

在学术数据服务方面,需要 OpenAlex 或 Semantic Scholar 提供稳定、高效且调用规则明确的 API,优先支持批量检索、可预期的访问额度、明确的限流与错误状态,并返回题名、摘要、DOI、作者、发表年份、Venue、开放获取状态及论文关系等可核验元数据。若能够同时稳定接入两个数据源,可进一步检验多源召回、跨源去重和证据融合的实际收益。考虑到在线索引持续更新,项目将记录 API 响应时间、数据源版本和原始响应,并构建本地冻结快照,以保证不同方法能够在一致候选条件下进行等预算比较。

在模型与运行环境方面,语义查询规划需要配置 DeepSeek 等模型服务的 API Key,本地 Cross Encoder 精排则需要具备稳定 CPU 或 GPU 推理能力的计算环境。系统已提供规则规划和基础排序降级路径,因此模型服务或精排组件不可用时仍可完成基本检索;稳定服务器和网络环境主要用于并发压力测试、在线时延评测、故障恢复测试及长时间运行验证。

在评测与用户验证方面,需要构建覆盖不同学科、不同约束复杂度和不同目标论文数量的人工标注查询集,并明确相关论文集合、硬约束满足情况和标注一致性。进一步的真实场景验证需要具有选题调研、开题报告或相关工作撰写任务的高校科研用户参与,以比较 ESASR 与常规检索流程在任务完成时间、有效论文率、约束遗漏率、来源核验成本和用户修正次数等指标上的差异。上述支持能够降低数据源波动、样本分布偏差和实验环境差异对结论的影响,并推动现有工程可行性证据扩展为可重复、可比较的外部有效性证据。

1.3.1 当前成果边界

ESASR 定位于基于题录、摘要与来源元数据的论文级检索和可解释证据组织,核心目标是将复杂自然语言查询转换为可执行约束,并形成来源可核验、过程可追踪、规模可自适应的论文候选集合。当前可验收能力包括结构化查询规划、OpenAlex 与 Semantic Scholar 双源召回、跨源去重与证据融合、约束覆盖诊断、证据缺口补检、本地 Cross Encoder 精排、自适应结果集选择,以及论文详情、检索轨迹、关系图、收藏与课题库等用户工作流。系统同时提供 API、CLI 和 Docker Compose 部署入口,并统一记录数据来源、调用成本、缺失字段和外部服务异常。

在大语言模型接入方面,ESASR 采用可配置的模型服务接口,由用户提供相应平台的 API Key。目前配置层支持 DeepSeek、Qwen、OpenAI、Kimi 以及其他兼容 OpenAI 接口规范的自定义模型服务。用户可通过 CLI 或环境变量配置模型平台、API Key、模型名称和服务地址,无需修改检索流程代码。需要强调的是,多模型接口兼容表示系统具备模型服务替换能力,并不代表所有模型均已完成同等规模的性能验证;当前正式在线 Token 与检索效率实验仅使用 DeepSeek-V4-Flash-0731,其他模型主要完成了配置与接口层面的兼容支持。

大语言模型在系统中仅承担复杂查询的语义解析和结构化规划,将自然语言输入转换为主题、方法、数据集、时间、Venue、开放获取及排除条件等统一约束,不直接生成论文条目,也不参与离线候选论文相关性指标的计算。检索结果来自 OpenAlex 和 Semantic Scholar 等真实学术数据源,本地 Cross Encoder 负责高相关候选的语义精排。因此,系统效果不归因于大语言模型生成论文答案,而归因于约束编译、证据缺

口路由、多源证据融合、局部精排和自适应结果集决策共同构成的检索闭环。

受专用查询规划标注数据、训练算力和跨领域评测条件限制，当前项目不具备对基础大语言模型开展大规模预训练或专项微调的条件，也未将模型微调、参数高效训练或私有化大模型部署纳入成果范围。项目采用现有模型 API 是在研发成本、调用灵活性和结果可复现性之间作出的工程选择。模型 API Key 未配置、额度耗尽或服务不可用时，确定性规则规划器仍可完成基础查询编译，使核心检索流程不依赖单一模型平台持续可用。

在论文关系组织方面，系统仅依据学术数据源返回的关系类型构建论文网络：参考文献与施引论文表示为有向引用关系，相关论文表示为无向关联关系，不将平台推荐关系推断为真实引文、共引或因果证据。当前成果暂不覆盖独立 arXiv 数据源召回、受版权保护的全文抓取、段落级证据定位、自动综述生成及递归引文网络扩展。这些能力需要额外的数据授权、全文解析和专项评测，因此作为后续扩展方向，不纳入现阶段性能结论。

上述边界使模型使用方式、检索功能、实验指标和可运行系统保持一致，避免将模型接口兼容表述为多模型性能优势，也避免将题录与摘要检索外推为全文理解或知识生成能力。同时，统一模型服务接口、规则降级路径和结构化检索协议为后续开展模型对比、查询规划微调及全文证据抽取保留了明确的扩展入口。

2 项目规划

2.1 整体目标

固定动作链无法根据查询难度调整检索深度，容易在简单查询上浪费预算、在复杂查询上提前停止。ESASR 以统一证据状态 $E_t = (C_t, G_t, S_t, B_t)$ 协调全链路，其中 C_t 表示约束覆盖， G_t 表示证据缺口， S_t 表示候选排名分布， B_t 表示剩余预算。系统据此选择补检、精排、扩展结果集或停止，使每一步动作都有状态依据与成本上限；图 1 展示该闭环如何把复杂科研问题转化为可审计论文集合。




图 1 ESASR 整体框架。复杂科研问题经约束编译、缺口路由、证据融合、局部精排和自适应选择形成可审计论文集合。

竞赛作品不仅需要算法有效，还必须解决“结果能否复核、系统能否运行、依赖失效时能否保持可信”的完整性交付难题。ESASR 因而把总体目标定义为可演示、可评测、可复现和可降级的复杂学术检索系统，并以四项相互约束的创新实现该目标：CQC 将复合意图转化为硬约束与软证据，EGRR 以证据缺口和剩余预算决定检索深度，MEFR 与 LCER 在受控候选池内提升排序质量，CARS 根据分数结构确定结果规模。中英文界面、成本统计工具和容器化部署包承担工程验证，来源失败、缺失元数据和关系类型则以显式状态传播。该设计使算法创新、量化证据和系统交付共享同一可信边界，避免把功能堆叠误写为性能提升。

2.2 技术创新点

多模块系统容易陷入“组件越多即创新越强”的技术堆叠。ESASR 以是否改变关键决策、是否解决明确难点、是否存在可验证收益作为创新判据，将 CQC、EGRR、MEFR、LCER 与 CARS 组织为一条证据状态主线，而非并列工具集合。每个模块均对应一个可复现的输入、状态变化和消融接口；已有数据只支持相应范围内的结论，尚未完成等预算验证的能力仅陈述为工程机制。由此，创新性建立在问题闭环和证据

闭环之上，而非模块命名或模型数量之上。

2.2.1 创新 1: 约束感知查询编译器 (CQC)

自由文本中的主题、方法与过滤条件常被检索器混为同类关键词，导致硬约束遗漏，并使通用大模型承担不必要的重复规划成本。CQC 采用“统一约束模式加双路径编译”解决该难点，将输入映射为主题、方法、数据集、领域、时间区间、Venue、开放获取、包含词与排除词；语义规划服务仅执行一次 JSON 结构化转换，默认输出上限为 500 tokens，结果写入 Redis，并将并发同键请求合并。模型平台未配置或输出异常时，确定性规则规划器生成同构计划，从而同时获得复杂表达解析能力、可控 Token 成本和无模型条件下的基本可用性。




图 2 CQC 查询编译流程。语义规划与确定性规则规划共享同一约束模式，并划分硬约束与软证据。

单纯把全部条件作为过滤器会因摘要缺失或元数据不完整误删潜在相关论文。CQC 因此将排除词、时间范围和强制 Venue 作为服务端硬过滤，将主题、方法、数据集、领域和开放获取作为软证据参与覆盖诊断与排序；Venue 进一步经过别名归一化、主会与 Workshop 区分，并按列表“或”语义解释。硬约束保证任务可用性，软证据保留不完整记录的再判断机会，相比统一关键词匹配更能兼顾约束准确性与候选召回率。

2.2.2 创新 2: 证据缺口驱动检索路由 (EGRR)

固定两轮检索无法区分“证据已经充分”和“关键条件仍未覆盖”，因而同时造成预算浪费与漏检风险。EGRR 以候选池的证据缺口替代固定轮次作为路由信号：OpenAlex 与 Semantic Scholar 首轮并行召回后，系统依据 DOI、数据源 ID 和规范化标题去重，保留信息更完整的记录并合并来源与命中子查询；随后对每个软约束 g_j 计算覆盖状态：

$$c_j = \max_{d_i \in D} m_{ij}, \quad G = \{g_j \mid c_j < \tau_j\}. \quad (2)$$

仅当 $G \neq \emptyset$ 且剩余任务预算 $B > 0$ 时，系统才将缺口与原主题组合为第二轮查询。补检由确定性模板生成，不增加模型规划调用；两轮共享最多 4 个子查询和 8 个数据源检索任务的默认上限。该机制把“继续检索”转化为由缺口收益和预算共同约束的决策，相比无条件扩展更节省调用，相比单轮召回又能针对未覆盖条件定向补证。




图 3 EGRR 检索路由。首轮多源召回与可选引文扩展形成候选证据状态；覆盖缺口与剩余预算共同决定是否补检。

EGRR 的技术优势在于将价值受限的信息获取落实为可审计状态转换：每次补检均记录触发缺口、生成查询、逻辑调用和覆盖变化。流程测试已经支持其可执行性、预算上限与决策可追踪性，但现有证据尚不足以宣称端到端质量增益；该边界需要在冻结在线响应的等预算对照中由无补检、固定补检与缺口补检共同验证。明确区分“机制成立”与“性能优越”提高了创新结论的可信度。

2.2.3 创新 3：多源证据融合与局部语义精排 (MEFR+LCER)

单一来源排序难以同时利用文本匹配、跨源一致性和约束覆盖，而直接对全候选执行深度语义模型又会产生过高推理开销。MEFR 先将词法相关性、RRF、查询覆盖、来源一致性和权威性信号归一化为可解释基础分数：

$$b(d, q) = w_l L + w_r R + w_c C + w_a A + w_v V, \quad (3)$$

其中 L 为标题与摘要等权词法得分， R 为跨来源和子查询的倒数排名融合， C 为查询约束覆盖， A 为多源一致性， V 为由 Venue、引用和开放获取构成的权威性证据，硬约束在融合前执行。该分层设计先以低成本证据压缩候选空间，再把语义模型集中于可能改变排序的位置，使每个分量可追踪并为消融实验保留独立接口。

词法排序对同义表达和复杂语义关系敏感，但全量 Cross Encoder 精排会显著放大时延。LCER 仅处理基础排序的配置化 Top-N 候选；当前工程默认 $N = 40$ ，离线对照为保持统一候选条件采用 $N = 20$ 。对查询 q 与论文题名/摘要 d ，本地

cross-encoder/ms-marco-MiniLM-L6-v2 生成语义分数 $r(d, q)$ ，并与基础证据分数融合为

$$s(d, q) = 0.65 r(d, q) + 0.35 b(d, q). \quad (4)$$

配置化候选前缀将语义建模集中在最可能改变排序的局部区域，兼顾排序收益与部署成本；模型未安装或推理异常时，系统保留 MEFR 排序并记录降级原因。离线消融显示 LCER 在相同候选条件下进一步提高 Top-1 Macro F1，说明该模块提供的是可测量的排序修正，而非无证据的模型叠加。




图 4 MEFR 与 LCER 分层排序。多源证据先形成可解释基础排序，本地 Cross Encoder 仅重排配置化 Top-N 候选前缀。

2.2.4 创新 4：置信度门控自适应结果集

固定 Top-K 隐含“所有查询具有相同答案规模”的不合理假设：候选分数高度集中时，固定较小 K 会遗漏近似并列论文；分数快速衰减时，固定较大 K 又会引入低相关结果。CARS 以候选置信质量与相邻落差共同决定截断位置，使结果规模随查询证据结构变化。

对通过最低相关性边界的有序候选，CARS 不预设固定 K ，而是将非负排序分数归一化为质量权重 $w_i = s_i / \sum_j s_j$ ，计算前缀累计质量 $C_k = \sum_{i=1}^k w_i$ 。给定范围档位 λ ，系统选择同时满足目标质量覆盖与显著分数断层的最小截断点：

$$K_\lambda = \min \{k : C_k \geq \tau_\lambda, s_k - s_{k+1} > \delta_\lambda\}. \quad (5)$$

若达到覆盖目标后边界候选与下一候选没有明显落差，选择器继续扩展，直至出现可信断层或触及相关性边界。因此“精准”档可保留多篇近似并列论文，“扩展”档以 $\tau_\lambda = 0.80$ 覆盖主要质量，“广泛”档返回候选池内全部达到相关性边界且满足硬约束的论文。滑动条联合调节质量覆盖、最低绝对分数、相对首位比例与断层阈值，在误报风险和证据覆盖之间形成连续控制； w_i 仅表示归一化排序质量而非概率，从而避免把启发式分数误述为校准置信度。

五档工程策略的参数空间尚未形成独立测试证据，直接用工程能力替代实验结论会造成外推过度。为隔离“分数门控是否有效”这一核心问题，现有对照采用一至两篇的受控特例：规则仅在100条开发查询上确定，当第二候选满足 $s_2 \geq 0.60$ 、 $s_2/s_1 \geq 0.85$ 且 $s_1 - s_2 \leq 0.10$ 时扩展，并在100条独立测试查询上只评估一次。该设计验证基本门控趋势，同时把五档动态截断保留为需要专项评测的工程扩展，确保性能结论不越过证据边界。




图 5 CARS 工程策略。系统依据累计质量、绝对分数、相对首位比率与相邻分数断层选择连续候选前缀；五档范围均不绑定固定 K ，受控实验中的一至两篇规则仅作为独立对照。

3 实施方案

3.1 技术可行性分析

复杂学术检索同时依赖交互、检索编排、状态存储与关系组织，单体实现会把算法状态、用户状态和外部故障耦合在一起，削弱可维护性与可验证性。系统采用分层架构：Vue 3、TypeScript、Pinia、Element Plus、ECharts 与 G6 承担复杂查询输入和证据呈现；FastAPI 以 Search、Papers、Auth 和 User 四组路由隔离业务边界；PostgreSQL、Redis 与 Neo4j 分别承载业务数据、检索缓存和论文关系。各层通过结构化接口交换计划、候选与状态，使算法替换不影响前端协议，数据服务异常也能被独立定位。




图 6 系统数据流与可信边界。交互、编排、学术数据服务和状态存储分层解耦，错误、来源和缺失字段显式传播。

仅返回论文列表无法证明系统按预期执行，也无法区分算法成本与外部服务成本。完整检索接口因此同步返回查询计划、候选论文、阶段轨迹、覆盖变化和成本指标，并逐查询记录规划 Token、逻辑检索调用、底层 HTTP 尝试、精排耗时与端到端时延；论文详情复用搜索缓存，列表返回时恢复筛选、排序和滚动状态，避免重复调用学术 API 或模型服务。OpenAlex、Semantic Scholar、本地 Cross Encoder 和规则规划器均位于同一生产路径，前后端构建、自动测试与容器化部署验证了该分层方案具备可运行、可测量和可替换的工程基础。

3.2 技术细节

3.2.1 来源、缺失与关系语义

外部 API 失败、演示数据混入和缺失字段伪填充会直接破坏评测真实性。系统对 OpenAlex 与 Semantic Scholar 采用严格调用语义：真实请求失败时，异常进入运行轨迹和健康状态，离线演示论文不得进入计分池；兼容展示接口返回的离线卡片统一标记为 Offline Demo/offline_fallback；缺失年份、摘要或 DOI 保持空值并由

metadataMissing 暴露。该设计以显式不确定性替代伪完整数据，使展示、评测和故障诊断共享同一事实来源。

论文关系图的主要风险是把平台相关性推荐误解释为真实引文证据。系统将参考文献与 citing papers 编码为有向 CITES, 将 OpenAlex related works 编码为无向 RELATED, 并在前端分别使用箭头和虚线呈现。关系类型从数据源到界面保持一致, 既保留探索价值, 又阻止用户将统计相关性误判为引用事实。

3.2.2 部署、安全与可降级运行

多依赖系统的工程难点在于密钥泄漏、组件状态失真和局部故障扩大。Docker Compose 将 Web、API、PostgreSQL、Redis 与 Neo4j 隔离部署, Web 容器仅承载静态页面与反向代理, 模型和学术 API 密钥只注入 API 容器, 真实配置以只读方式挂载且不入前端产物; 健康接口联合检查 API 与三类状态服务, 任一核心依赖异常即返回 HTTP 503 和 overall=degraded。该部署边界把安全控制、就绪判断与服务编排统一起来, 避免“页面可访问”被误判为“系统可用”。




图 7 容器化部署拓扑。外部学术 API、内部数据服务和用户流量在 API 层汇合, 密钥与业务状态均与前端隔离。

表 2 关键故障与降级行为

故障	系统行为	可信保证
模型规划服务未配置或输出异常	切换确定性规则规划器	查询仍可执行，切换原因留痕
单一学术 API 限流	全局限速、指数退避或使用另一来源	失败来源和 HTTP 尝试可见
Cross Encoder 不可用	保留基础融合排序	不扩大为整次检索失败
PostgreSQL 开发环境不可达	可切换本地 SQLite	仅用于开发，不伪装生产状态
核心依赖异常	健康接口返回 503/degraded	部署编排据真实状态判断就绪

3.3 实验设计与结果

证据分层与防止口径混淆。算法链路同时改变候选排序与结果数量，若把两类效应合并评测，将无法判断增益来自排序改进还是返回篇数变化。实验因此围绕两个独立问题组织证据：排序模块实验检验词法权重、融合与 LCER 是否改善首位相关性；输出策略实验在冻结候选上检验 CARS 是否优于固定 Top-K。两层实验使用独立的数据划分和控制变量，使每项性能变化能够映射到明确模块，并避免把不同口径拼接为缺乏解释力的系统总分。




图 8 分层实验协议。排序模块在固定 200 条样本上比较，输出策略在 100 条开发集上选规则并在 100 条独立测试集上评估。

在线学术索引持续变化，直接比较不同时间的 API 响应会把数据漂移误当作算法差异。质量实验采用 ScholarGym 冻结本地镜像，从 2,536 条查询中按来源分层抽

取 200 条，其中 PaSa AutoScholar、PaSa RealScholar 与 LitSearch 分别为 156、4 和 40 条；论文库固定为 570,206 篇，随机种子为 2026。Gold 依次依据 arXiv ID、DOI、数据源 ID 和规范化标题匹配，以逐查询 F1 的算术平均为主指标，并联合报告 Precision、Recall、MAP、nDCG、置信区间、时延和调用成本。固定语料、身份匹配顺序与多指标报告共同隔离算法贡献并约束结论范围。

排序模块消融。排序模块的关键难点是区分有效设计与无收益的技术叠加。所有配置使用相同的 200 条查询、论文快照、Top-100 候选上限和 Top-1 输出：标题偏置词法召回将标题与摘要权重设为 5:1，等权词法召回改为 1:1，MEFR+LCER 在等权召回基础上精排 Top-20，多路 RRF 方案则增加路由融合后使用相同精排。表 3 显示，标题与摘要等权贡献最大绝对增益，LCER 提供进一步改善，而额外多路 RRF 未产生增益。该结果将最终路径收敛为必要模块组合，并把无收益的复杂化保留为消融证据。

表 3 排序模块消融结果（固定分层样本 $n = 200$ ）

方法	P@1	R@1	F1@1	F1 95% CI	延时/ms
标题偏置词法召回	0.2250	0.1745	0.1862	[0.1377, 0.2371]	—
等权词法召回	0.3000	0.2301	0.2466	[0.1928, 0.3015]	1022.3
等权词法召回 + LCER	0.3300	0.2454	0.2649	[0.2092, 0.3226]	741.7
多路 RRF + LCER	0.3200	0.2389	0.2562	[0.1982, 0.3132]	905.0

相较等权词法召回，加入 LCER 后 Top-1 Macro F1 从 0.2466 提升至 0.2649，绝对增益为 0.0183、相对增幅约 7.4%；200 条查询全部完成，平均精排耗时为 285.3 ms，且冻结语料条件下不产生远端 API、模型规划或 Token 消耗。配对 bootstrap 差值区间 $[-0.0017, 0.0408]$ 包含 0，因此该证据支持“局部语义精排呈正向趋势并具备可复现效率”，尚不足以支持稳定优越性。量化收益与不确定性同时报告，使性能提升具有明确比较对象和统计边界。

在线 Token 与检索效率评测。离线零 Token 只能说明排序实验被隔离，不能代表真实系统的运行成本。在线评测据此从 ScholarGym 的 PaSa AutoScholar、LitSearch 和 PaSa RealScholar 各无放回抽取 10 条有效查询 ($n = 30$ ，随机种子 20260828)，采用 EGRR 配置接入 OpenAlex 与 Semantic Scholar，并将单条查询限制在最多 8 次逻辑检索调用。规划使用 DeepSeek-V4-Flash-0731（API 模型名 deepseek-v4-flash，默认思考模式），强制绕过规划缓存，Token 仅以 API 响应 usage 计量而不使用本地估算。LCER 不产生模型 Token，因而与规划成本分账；该设计得到可核验的真实消耗，同时避免把在线规划检索耗时与本地排序耗时混为同一指标。

表 4 真实联网规划与多源检索效率 (分层样本 $n = 30$)

指标	总量	均值	中位数 / P95	计量口径
总 Token	24,840	828.0	886 / 2,453	API usage
输入 Token	5,811	193.7	240.5 / 474	30 条查询
输出 Token	19,029	634.3	645 / 1,979	含思考 Token
思考 Token	15,759	525.3	482.5 / 1,838	输出 Token 的子集
逻辑检索调用	166	5.53	4 / 8	每条上限 8 次
在线链路耗时/ms	802,290	26,743	15,911.5 / 90,065	真实 API 墙钟时间

在线样本中, 22 条查询进入模型规划, 8 条由确定性规则完成; 32 次模型请求包含 2 次解析失败后的重试, 失败尝试产生的 Token 全部计入成本。22 条模型查询的平均消耗为 1,129.1 Token, 中位数为 977, P95 为 2,453; 30 条检索流程均完成, 平均返回 19.67 篇候选, 但 3 条记录到 Semantic Scholar HTTP 异常, 对应 10% 的外部故障查询率。按 2026 年 8 月 28 日公开价格并保守地将全部输入视为缓存未命中, 规划费用估算为 0.0138 美元 (非高峰) 或 0.0277 美元 (高峰)。实测 Token、失败计费与估算价格分开陈述, 既表明规则路由能够避免部分模型调用, 也保留了服务负载对时延和可用性的真实影响。

自适应输出策略对照。固定增大 Top-K 虽能提高召回率, 却可能因低相关候选增加而降低集合质量, 必须在相同排序上隔离“返回多少”的影响。200 条冻结候选按来源和稳定哈希拆分为 100 条开发集与 100 条测试集, 两侧均含 78 条 AutoScholar、2 条 RealScholar 和 20 条 LitSearch; CARS 仅在开发集搜索 8,064 组规则, 测试 Gold 不参与阈值或最大返回数选择。固定 Top-1、Top-2、Top-3、Top-5 与 CARS 共用同一测试查询和候选排序, 从而将性能差异限定为输出策略贡献。

表 5 自适应输出策略独立测试结果 ($n = 100$, 候选冻结)

方法	P	R	Macro F1	F1 95% CI	平均返回数
固定 Top-1	0.3300	0.2241	0.2475	[0.1715, 0.3255]	1.00
固定 Top-2	0.1900	0.2537	0.1986	[0.1424, 0.2537]	2.00
固定 Top-3	0.1400	0.2697	0.1665	[0.1219, 0.2105]	3.00
固定 Top-5	0.0960	0.2926	0.1304	[0.0991, 0.1627]	5.00
CARS	0.3350	0.2374	0.2571	[0.1812, 0.3350]	1.07

固定增加 K 提高了 Recall, 却连续降低 Precision 与 Macro F1; CARS 只在 7% 的测试查询上保留第二篇, 便将 Macro F1 从固定 Top-1 的 0.2475 提升至 0.2571, 绝对增益为 0.0097, 平均返回数仅由 1.00 增至 1.07。配对差值区间 $[0.0000, 0.0267]$ 位于非负边界但仍包含 0, 因而支持“轻量门控以接近 Top-1 的规模呈现正向平衡趋势”, 而非确定性提升。该对照排除了单纯增加篇数造成的伪改进, 为动态结果规模提供了直接证据。




图 9 消融与对照结果。a, 标题摘要等权与局部语义精排逐步改善 F1, 多路 RRF 未优于最终候选排序器; b, 固定扩大结果集导致 F1 下降, CARS 以接近 Top-1 的返回规模取得最高测试 F1。

真实查询案例与适用边界。词法匹配在术语重叠但任务语义不同的论文之间容易发生首位误序。AutoScholarQuery_test_548 要求检索借助 Transformer 提高低纹理区域准确率的半稠密匹配方法, Gold Set 包含 LoFTR、ASpanFormer 与 MatchFormer;

等权词法排序却将未命中 Gold 的 *Multi-Spectral Visual Odometry without Explicit Stereo Matching* 置于首位。LCER 在完全相同的候选池中把 LoFTR 提升至第一位、MatchFormer 提升至第二位，使该查询 F1@1 从 0 提高到 0.5。该案例说明局部语义精排能够纠正可解释的词法误序，但单例证据仅用于揭示作用机制，不能替代跨查询统计结论。

现有证据的主要限制来自摘要缺失、同义表达覆盖不足、分来源样本不均衡，以及在线 API 的限流、更新和排序漂移。ESASR 不以默认值掩盖这些不确定性，而是将缺失字段、失败来源、数据哈希、随机种子和阈值协议写入结果与实验清单，使相同问题能够在冻结响应和跨语料条件下复验。该处理不能消除数据偏差，却能把不可控外部因素转化为可观察、可比较的实验边界，从而提高结论的可审计性。

3.4 作品完整性与展示闭环

可运行系统。算法报告若缺少可执行入口，评委无法判断结果来自真实系统还是离线脚本拼接。ESASR 以公开代码仓库交付 npm CLI、Docker Compose、配置模板与启动脚本，并通过终端引导完成模型和学术搜索 API Key 配置；未配置 LLM 时，规则规划器仍保持基本检索能力。表 6 将算法测试、打包验证、前端构建与离线评测映射到具体复现入口，使作品完整性能够由代码、命令和结果文件共同核验。

表 6 工程验证与复现入口

对象	结果	覆盖内容	复现入口
后端自动化测试	63/63 通过	来源、缺失元数据、约束、补检、精排、动态范围、缓存、限流与指标	tests/
CLI 与打包	9/9; 300.4 kB	初始化、端口、密钥、重启与发布文件白名单	npm test、pack:check
前端生产构建	类型检查与构建通过	Vue/TypeScript 类型和静态产物	npm run build
排序模块评测	200/200 完成	固定语料、候选、F1/MAP/nDCG、成本与时延	离线评测脚本
自适应选择评测	100 dev + 100 test	固定 Top-K、CARS、阈值隔离和配对 bootstrap	选择策略脚本

交互与结构化输出。传统搜索界面只呈现最终列表，用户无法核验约束是否生效、补检为何触发以及排序依据来自何处。ESASR 将查询计划、首轮召回、覆盖诊断、缺口补检、精排和结果选择以阶段状态呈现在同一结果页；论文卡片同时显示题名、作者、Venue、年份、摘要、来源、推荐理由与开放获取入口，详情页进一步提供分型关系图、收藏和课题库。该交互把算法内部状态转化为可理解证据，使“结果相

关”扩展为“过程可解释、来源可追踪、结果可沉淀”，而检索质量仍由独立实验而非界面观感证明。

固定演示查询与结果解释。为同时覆盖主题、方法、困难场景、年份、Venue、开放获取、数据集偏好与排除条件，作品展示采用如下固定检索词：

寻找 2020 年以来使用 Transformer 提升弱纹理或大视角变化场景下图像匹配性能的论文，要求发表于 CVPR、ICCV 或 ECCV 且可开放获取，优先包含 ScanNet 或 MegaDepth 实验，排除纯光流方法和综述文章。

演示查询若约束过少，容易把普通关键词搜索包装为复杂检索能力。固定检索词同时覆盖主题、方法、困难场景、数据集、Venue、年份、开放获取与排除项八类条件，并以同一输入检验编译、预算路由、跨源召回和硬约束过滤。在 2026 年 8 月 26 日的本地在线复测中，确定性 CQC 在 14 ms 内生成 5 个英文候选子查询，EGRR 在预算内执行其中 4 个；OpenAlex 与 Semantic Scholar 返回 120 条原始候选，经跨源去重和约束过滤后保留 4 篇。该链路以 8 次数据源调用、零远端模型规划和 9.088 s 端到端耗时完成，且无数据源失败，说明复杂约束处理可以在不依赖模型调用的条件下形成可运行闭环。

复杂检索的验收重点不是结果数量，而是候选能否满足硬约束并暴露未充分支持的软条件。系统返回 CVPR 2021 的 LoFTR、ECCV 2022 的 ASpanFormer、ICCV 2023 的 CasMTR 与 ICCV 2025 的 CoMatch，四篇均满足 2020 年以来、指定会议、开放获取、Transformer 和图像匹配等硬约束；方法证据分别对应稠密注意力匹配、自适应注意力跨度、级联空间关键点建模和亚像素级半稠密匹配。最终证据覆盖率为 60%，未由题录或摘要稳定支持的数据集偏好与困难场景继续标记为缺口。即使关闭 LCER，MEFR 仍完成可解释排序，体现出该展示的核心价值在于硬约束零违规与证据状态透明，而非以不完整元数据制造“全部命中”的表象。




图 10 自然语言检索首页。示例提示帮助用户表达主题、时间、方法和成果约束。




图 11 检索结果页。查询计划、覆盖状态、运行轨迹和带来源证据的论文候选在同一页面呈现。




图 12 论文详情页。页面汇总元数据、摘要、开放获取入口、相关论文和关系信息。

3.5 应用价值与科研服务前景

科研应用定位。大规模学术索引擅长覆盖，语言模型擅长理解自然语言，但前者难以表达复合约束，后者又缺少稳定来源与成本边界。ESASR 不重复建设底层索引或生成论文清单，而是以 CQC、EGRR、MEFR、LCER 和 CARS 将两类能力组织为可控检索编排层，并将来源、覆盖、预算与失败状态贯穿科研工作流。该定位使系统能够复用开放学术基础设施，同时提供通用平台缺失的约束可执行性、过程可复现性和故障可降级性，适用于选题调研、Related Work、跨学科检索与课题组证据管理。

表 7 科研服务场景与技术验收指标

科研场景	系统支持	主要验收指标
复杂选题与开题调研	复合约束编译、多源召回和证据覆盖诊断	有效论文率、硬约束违反率和任务完成时间
Related Work 与跨学科检索	可解释排序、局部语义精排和来源追踪	Top-K 检索质量、来源完整性和重复结果比例
课题组证据管理	共享课题库、检索轨迹和论文关系组织	结果可复现率、检索记录完整性和用户可用性
科研信息服务	检索编排 API、统一身份与结构化结果接口	并发能力、p95 时延、故障恢复时间和数据合规性

科研服务与技术验收。现有离线指标能够表明排序趋势，却不能直接回答系统是否减少研究者的检索负担。系统已提供账户、课题库、检索轨迹、来源核验和统一指标日志，可在开题调研与 Related Work 任务中记录完成时间、有效论文率、重复检索率、约束遗漏率和用户修正次数，并与常规检索流程进行配对比较。该用户级验证把算法质量转化为科研效率与结果可用性证据，是从技术可行性迈向科研服务价值所需的关键验收环节，而非泛化的应用前景描述。

3.6 可靠性保障与扩展验证

可靠性与合规保障。真实科研服务必须面对 API 限流、模型输出异常、精排资源不足、元数据缺失和公网攻击面，任何单点失效都可能使结果不可用或不可置信。系统以全局速率控制、指数退避、缓存与多源互补处理学术 API 波动，以统一模式校验和规则规划接管模型异常，以 MEFR 保留精排降级路径，并以多源补全与显式缺失标记保护元数据真实性；公网部署通过 CORS、JWT、密钥轮换和 HTTPS 隔离访问风险，仅使用授权数据和可核验论文记录。多层防护的工程价值不在于宣称零故障，而在于使故障范围、降级行为和恢复条件均可观察、可测试。

优先验证清单。现有证据仍存在五类外部有效性缺口。CARS 的跨学科稳定性需要更大冻结测试集与预注册阈值；EGRR 的收益需要在相同 API 任务数、相同时间窗口和冻结响应下，与无补检及固定二轮检索比较 F1 和单位真阳性开销；CQC 的解析能力需要槽位 F1、硬约束违反率和分类型错误支持；系统可靠性需要并发、限流、断网与依赖故障注入下的 p50/p95 时延和恢复时间；科研价值需要真实用户任务中的效率、修正次数和来源核验行为验证。上述验证分别对应稳定性、因果归因、解析准确性、工程韧性和用户价值，能够把当前可行性证据扩展为可推广结论，而非简单增加实验数量。

3.7 计划与分工

多模块竞赛项目的主要管理风险是算法、实验与工程责任交叉，导致指标无人复核或交付接口相互推诿。项目以“责任主体、验收证据、版本节点”三者绑定的治理方式控制该风险：队长对需求基线、评测口径、风险闭环和最终验收负责；队员 A 对 CQC、EGRR、MEFR、LCER、CARS 及其量化证据负责；队员 B 对数据源、后端接口、前端联调、部署测试和提交材料负责。表中日期仅界定责任窗口，技术结论仍以冻结实验、自动测试和可运行产物为验收依据，从而保证工作分工服务于证据闭环而非形成过程流水账。

表 8 项目阶段、版本节点与匿名成员分工

阶段	起止日期	版本节点	任务分工与验收产物
需求与架构	2026.05.22– 2026.06.12	v0.1– v0.2	难点：复合查询缺少统一验收口径。队长负责需求与指标边界，队员 A 负责约束模式，队员 B 负责架构与接口；以需求基线、数据流和接口规范作为验收证据。
核心模块开发	2026.06.13– 2026.07.10	v0.3	难点：检索决策、数据源和排序模块需解耦。队员 A 负责 CQC、EGRR、MEFR、LCER 与 CARS，队员 B 负责双源接入、去重与缓存，队长负责接口一致性；以可运行检索链路验收。
实验验证	2026.07.11– 2026.08.08	v0.4	难点：组件收益易受数据与输出规模混淆。队长负责冻结协议，队员 A 负责消融、置信区间与错误分析，队员 B 负责脚本和证据归档；以可复现实验包验收。
集成与优化	2026.08.09– 2026.08.26	v0.5	难点：外部依赖故障可能破坏展示可信度。队员 A 负责性能与故障回归，队员 B 负责联调、部署和交互，队长负责风险闭环；以稳定演示系统和降级证据验收。
提交定版	2026.08.27– 2026.08.31	v1.0	难点：代码、指标与材料必须保持一致。队长负责版本冻结，队员 A 负责数据与复现入口，队员 B 负责 PDF、附件和仓库；以一致性核验通过的提交包验收。

3.7.1 交付与复现

项目复现的难点在于环境、配置、数据划分和模型状态任一缺失都会使指标无法核对。交付包以根目录启动脚本统一构建服务，以精排开关控制本地 Cross Encoder，以环境变量示例和配置模板隔离真实密钥；实验目录同时保存 Gold、逐查询预测、指标、置信区间、开发/测试拆分、阈值搜索记录、数据哈希、随机种子和模型名称。后

端与 CLI 测试、前端构建、两层离线实验、五类服务健康状态、复杂查询轨迹、组件故障行为及原始响应共同构成验收矩阵，使复现不依赖口头步骤或开发者本机状态。

技术探索过程若混入主报告，会削弱最终方案的因果主线；若完全删除，又不利于核验关键选择依据。项目因此将探索顺序、中间对照、技术瓶颈与解决证据独立收录于《技术迭代与问题解决记录》，主报告只保留最终方法、必要消融和结论边界。双层材料结构使评委能够先判断创新与性能，再按需追溯工程决策，兼顾答辩表达效率和研发过程可信度。

4 参考资料

1. 中国研究生创新实践系列大赛，第八届中国研究生人工智能创新大赛赛题揭榜公告，赛题“科研场景下复杂学术查询的智能论文搜索与推荐”，2026。
2. Ajith A., Xia M., Chevalier A., et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP, 2024, pp. 15068–15083.
3. Jeong S., Baek J., Cho S., et al. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. NAACL, 2024.
4. Asai A., Wu Z., Wang Y., et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. ICLR, 2024.
5. Kang S., Zhang Y., Jiang P., et al. Taxonomy-guided Semantic Indexing for Academic Paper Search. EMNLP, 2024.
6. Cormack G. V., Clarke C. L. A., Büttcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. SIGIR, 2009.
7. Nogueira R., Cho K. Passage Re-ranking with BERT. arXiv:1901.04085, 2019.
8. OpenAlex Documentation. <https://docs.openalex.org/>.
9. Semantic Scholar Academic Graph API Documentation. <https://api.semanticscholar.org/api-docs/>.
10. FastAPI Documentation; Vue.js Documentation; Docker Compose Documentation.