

# 第八届中国研究生人工智能创新大赛

**ESASR**

证据状态驱动的自适应学术检索框架

**Evidence-State Adaptive Scholarly Retrieval**

项目报告

团队名称: **Justifying**

参赛组别: 企业赛题组

提交日期: **2026.08.26**

## 目录

|                 |           |
|-----------------|-----------|
| 摘要              | 1         |
| <b>1 项目概况</b>   | <b>2</b>  |
| 1.1 背景和基础       | 2         |
| 1.2 场景和价值       | 2         |
| 1.3 所需支持        | 3         |
| <b>2 项目规划</b>   | <b>3</b>  |
| 2.1 整体目标        | 3         |
| 2.2 技术创新点       | 4         |
| <b>3 实施方案</b>   | <b>7</b>  |
| 3.1 技术可行性分析     | 7         |
| 3.2 技术细节        | 8         |
| 3.3 实验设计与结果     | 9         |
| 3.4 作品完整性与展示闭环  | 12        |
| 3.5 应用价值与科研服务前景 | 14        |
| 3.6 风险、合规与下一步验证 | 15        |
| 3.7 计划和分工       | 15        |
| <b>4 参考资料</b>   | <b>16</b> |

## 记录更改历史

[illegible]

## 摘要

面向同时包含主题、方法、数据集、时间、发表平台、开放获取与排除条件的复杂科研查询，现有关键词检索依赖反复试词，通用大模型又存在来源不可核验、约束遗漏和固定调用成本等问题。本项目将这一任务定义为预算约束下的证据集合构建：系统不仅要找到相关论文，还要根据当前候选证据判断缺什么、是否继续检索以及最终应返回多少篇。

项目提出证据状态驱动的自适应学术检索框架（Evidence-State Adaptive Scholarly Retrieval, ESASR）。框架包含约束感知查询编译、证据缺口驱动检索路由、多源证据融合排序、局部语义交叉编码精排和置信度门控自适应结果集。系统在 OpenAlex 与 Semantic Scholar 上执行预算受控的多源检索，本地 Cross Encoder 仅重排 Top-20；CARS 根据第二候选的绝对分数、相对分数和相邻落差，按查询返回一篇或两篇。整个链路保留来源、缺失字段、命中约束和阶段轨迹，外部故障不会被演示数据静默替代。

项目在 ScholarGym 本地镜像上开展两层验证。排序模块实验从 2,536 条查询中按来源固定抽取 200 条，在 570,206 篇论文、Top-100 候选池和零远端 API/Token 预算下比较各模块。等权词法召回结合本地 Cross Encoder 的 Top-1 Macro F1 为 **0.2649**，bootstrap 95% 置信区间为 **[0.2092, 0.3226]**，比等权词法召回提高 0.0183。输出策略实验将同一批冻结候选按来源拆为 100 条开发查询和 100 条独立测试查询，开发集搜索 8,064 组规则，测试集只评估一次。CARS 在测试集上取得 **0.2571** Macro F1，固定 Top-1 为 0.2475，平均返回 1.07 篇。两项配对区间均包含 0，因此本文只报告初步正向趋势，不作统计显著性承诺。

工程侧已形成 Vue 3、FastAPI、PostgreSQL、Redis、Neo4j 和 Docker Compose 组成的可运行系统，后端自动化测试 48/48、CLI 测试 8/8、前端类型检查与生产构建通过。离线 200 条查询全部完成，平均端到端延时 741.7 ms，其中本地精排平均 285.3 ms。现有证据证明系统可运行、可审计和可复现，但不等同于赛事隐藏测试成绩；在线多源响应漂移、覆盖补检端到端增益和更大规模跨领域泛化仍需验证。

关键词：学术文献检索；自主智能体；约束感知查询；证据缺口；多源融合；交叉编码精排；自适应结果集

# 1 项目概况

## 1.1 背景和基础

科研检索的困难不在于输入一个关键词，而在于将复合研究意图稳定映射到可核验论文集合。例如，“寻找 2021 年以后使用 Transformer 改善低纹理区域半稠密匹配、并发表于计算机视觉主会的开放获取论文”同时包含主题、方法、问题属性、时间、Venue 与开放获取约束。任何一个条件被遗漏，都可能使结果在语义上看似相关、在任务上却不可用。

本项目把每个查询表示为  $q = (I, H, B)$ :  $I$  是主题、方法、数据集等软意图集合,  $H$  是年份、排除词和强制 Venue 等硬约束集合,  $B$  是检索任务、模型推理与时延预算。给定多源候选集合  $D$ , 系统输出规模可变的论文集合  $S_q$ , 在满足硬约束的前提下平衡 Precision 与 Recall, 并控制调用成本:

$$\max_{S_q \subseteq D} F_1(S_q, G_q) - \lambda_1 C_{\text{api}} - \lambda_2 C_{\text{token}} - \lambda_3 C_{\text{latency}}, \quad (1)$$

其中  $G_q$  为查询对应的 Gold Set。该定义把“检索什么”“是否继续检索”和“返回多少”纳入同一证据状态决策。

## 1.2 场景和价值

ESASR 服务于科研选题、开题调研、Related Work、跨学科检索和个人论文管理。其价值不是替代研究者作出学术判断，而是把分散的“拆解问题、跨源查找、去重核验、保存证据、整理关系”压缩为一条可追踪 workflow。

表 1 用户痛点、系统响应与验收证据

| 用户痛点                | 系统响应                | 验收证据                     |
|---------------------|---------------------|--------------------------|
| 复合约束容易遗漏            | 结构化槽位、硬约束过滤与软证据覆盖诊断 | 查询计划、命中约束和未覆盖约束可见        |
| 跨平台结果重复且排序不一        | 多源并发、规范键去重与证据融合排序   | DOI、来源 ID、规范化标题和融合分量可追踪  |
| 固定检索动作浪费预算          | 覆盖缺口触发补检，补检不再调用 LLM | 逐查询任务数、HTTP 尝试、Token 和时延 |
| 固定 Top-K 难平衡精确率与召回率 | 置信度门控返回一篇或两篇        | 独立测试集与固定 Top-K 对照        |
| 大模型答案来源不明           | 返回真实论文记录而非生成式论文清单   | 来源、DOI、开放获取状态与缺失字段显式呈现   |

### 1.3 所需支持

为完成赛事级独立验证与规模化科研应用，项目当前最需要三类支持。第一，需要获得 OpenAlex 或 Semantic Scholar 至少一种高效、稳定的学术数据 API，支持较高并发或批量检索、充足且可预期的调用额度、明确的限流状态以及低时延响应；条件允许时，还需提供可冻结的响应快照或固定时间窗口，以保证在线对照实验可复现。第二，需要覆盖多学科、复合约束与真实科研表达的人工标注查询集，用于检验查询编译、约束满足和跨领域泛化能力。第三，需要稳定的实验服务器与高校科研用户测试环境，用于开展等预算在线消融、并发压力测试和真实任务可用性评估。上述支持分别对应数据获取效率、实验可信度和系统稳定性。

#### 1.3.1 当前成果边界

当前交付聚焦论文级检索与可解释候选组织。已实现结构化查询规划、OpenAlex 与 Semantic Scholar 双源召回、去重融合、覆盖诊断、缺口补检、本地精排、自适应结果集、详情与关系图、用户工作流和容器化部署。独立 arXiv 召回、受版权保护全文抓取、段落级证据抽取、自动综述生成和基于真实共引图的递归扩展不在本次效果承诺内。

## 2 项目规划

### 2.1 整体目标

ESASR 以统一证据状态  $E_t = (C_t, G_t, S_t, B_t)$  协调全链路： $C_t$  表示当前约束覆盖， $G_t$  表示证据缺口， $S_t$  表示候选排名分布， $B_t$  表示剩余预算。系统根据  $E_t$  决定下一步是补检、精排、扩展结果集还是停止。图 1 给出最终方案的完整链路。




图 1 ESASR 整体框架。复杂科研问题经约束编译、缺口路由、证据融合、局部精排和自适应选择形成可审计论文集合。

项目的整体目标是形成可演示、可评测、可复现、可降级的复杂学术检索系统。交付物包括中英文自然语言检索界面、预算受控的查询规划与多源检索链路、可解释排序与自适应结果集、离线评测和成本统计工具，以及可一键启动的容器化部署包。项目的可辨识创新归纳为四点：第一，约束感知查询编译将复合研究意图转化为硬约束与软证据；第二，证据缺口与检索预算联合驱动决定是否继续检索；第三，多源证据融合与局部语义精排在受控候选池内提升排序质量；第四，置信度门控自适应结果集根据候选分数结构决定返回规模。来源失败、缺失元数据、离线演示和关系类型同时以显式状态传播，构成四项创新共享的可信边界。已完成的模块、策略实验与工程回归分别陈述，尚未验证的在线增益不被表述为已证实创新。

## 2.2 技术创新点

本项目以 ESASR 为唯一技术主线，创新性不按组件数量计算，而按“是否改变检索决策、是否具备可验证收益”判断。CQC、EGRR、MEFR、LCER 与 CARS 是同一框架内的功能模块；未获得实验证据的能力只作为已实现策略报告，不被包装为效果结论。

### 2.2.1 创新 1：约束感知查询编译器（CQC）

约束感知查询编译器（Constraint-aware Query Compiler, CQC）将自由文本映射为统一模式：主题、方法、数据集、领域、时间区间、Venue、开放获取、包含词与排除词。远端 LLM 只承担一次 JSON 结构化规划，默认输出上限为 500 tokens；结果进入 Redis 缓存，并发同键请求合并为一次调用。未配置 Key 或远端输出异常时，规则规划器构造可执行计划。




图 2 CQC 查询编译流程。LLM 规划与确定性规则规划共享同一约束模式，并划分硬约束与软证据。

排除词、时间范围和强制 Venue 在服务端过滤；主题、方法、数据集、领域和开放获取参与覆盖诊断与排序，避免因摘要或元数据缺失造成过早误删。Venue 匹配采



用别名归一化与主会/Workshop 区分，Venue 列表按“或”语义解释。

### 2.2.2 创新 2：证据缺口驱动检索路由（EGRR）

证据缺口驱动检索路由（Evidence-Gap Retrieval Routing, EGRR）先在 OpenAlex 和 Semantic Scholar 上执行首轮并行召回。候选通过 DOI、数据源 ID 与规范化标题去重；同一论文的多份记录优先保留信息更完整者，并合并来源和命中子查询。对每个软约束  $g_j$ ，系统计算候选池覆盖：

$$c_j = \max_{d_i \in D} m_{ij}, \quad G = \{g_j \mid c_j < \tau_j\}. \quad (2)$$

仅当  $G \neq \emptyset$  且剩余任务预算  $B > 0$  时，系统把缺口与原主题组合为第二轮查询。补检使用确定性模板，不新增 LLM 调用；两轮共享最多 4 个子查询和 8 个数据源检索任务的默认上限。




图 3 EGRR 检索路由。首轮多源召回形成候选证据状态；覆盖缺口与剩余预算共同决定是否补检。

该机制属于价值受限的信息获取：只有当新检索可能弥补当前证据缺口且成本仍在预算内时才继续动作。代码已实现并通过流程测试，但离线语料无法复现在线响应，因此本报告只认定其为已实现的受控策略，不把它写成已经证实提升 F1 的结论。

### 2.2.3 创新 3：多源证据融合与局部语义精排（MEFR+LCER）

多源证据融合排序（Multi-source Evidence Fusion Ranking, MEFR）把词法相关性、RRF、查询覆盖、来源一致性和权威性信号归一化为基础分数：

$$b(d, q) = w_l L + w_r R + w_c C + w_a A + w_v V, \quad (3)$$

其中  $L$  为标题与摘要等权词法得分， $R$  为跨来源和子查询的倒数排名融合， $C$  为查询约束覆盖， $A$  为多源一致性， $V$  为 Venue、引用和开放获取构成的权威性证据。硬约束在融合前执行。



局部语义交叉编码精排(Local Cross-Encoder Reranking, LCER)仅处理基础排序的Top-20。对查询  $q$  和论文题名/摘要  $d$ ，本地 cross-encoder/ms-marco-MiniLM-L6-v2 产生语义分数  $r(d, q)$ ，最终分数为

$$s(d, q) = 0.65 r(d, q) + 0.35 b(d, q). \quad (4)$$

限制候选规模使语义建模集中在最可能改变首位结果的区域；模型未安装或推理异常时，系统保留基础排序并记录降级原因。




图 4 MEFR 与 LCER 分层排序。多源证据先形成可解释基础排序，本地 Cross Encoder 只重排 Top-20。

#### 2.2.4 创新 4：置信度门控自适应结果集 (CARS)

固定 Top-K 假设所有查询具有相同答案规模。

置信度门控自适应结果集 (Confidence-Gated Adaptive Result Set, CARS) 默认返回第一篇，仅在第二候选同时满足三项条件时扩展为两篇：

$$s_2 \geq 0.60, \quad \frac{s_2}{s_1} \geq 0.85, \quad s_1 - s_2 \leq 0.10. \quad (5)$$

三个门分别约束绝对可信度、相对接近度和局部落差，避免仅凭某一个未经严格校准的原始分数扩大结果集。因此本文使用“置信度门控”而非“概率校准”表述，不声称该分数满足概率校准性质。




图 5 CARS 自适应选择。规则在 100 条开发查询上确定，并在 100 条独立测试查询上只评估一次。

### 3 实施方案

#### 3.1 技术可行性分析

前端使用 Vue 3、TypeScript、Pinia、Element Plus、ECharts 与 G6，负责复杂查询输入、检索过程呈现、论文列表、详情和关系图。FastAPI 后端划分 Search、Papers、Auth 和 User 四组路由。PostgreSQL 存储业务数据，Redis 存储规划、结果和详情缓存，Neo4j 存储论文关系。




图 6 系统数据流与可信边界。交互、编排、学术数据服务和状态存储分层解耦，错误、来源和缺失字段显式传播。

完整检索接口返回计划、论文、阶段轨迹、覆盖变化和成本指标。系统逐查询记录规划 Token、逻辑检索任务、底层 HTTP 尝试、精排耗时和端到端时延。论文详情优先读取搜索阶段缓存，返回列表时恢复筛选、排序和滚动位置，从而避免重复调用学术 API 或 LLM。OpenAlex、Semantic Scholar、本地 Cross Encoder 和规则规划器均已接入现有代码路径，前后端构建、自动测试与容器化部署为方案可行性提供工程证据。

## 3.2 技术细节

### 3.2.1 来源、缺失与关系语义

完整检索对外部数据源使用严格调用：若真实 OpenAlex 或 Semantic Scholar 请求失败，故障进入轨迹和健康状态，不把离线演示论文注入计分池。兼容展示接口允许返回离线卡片，但统一标记为 Offline Demo/offline\_fallback。缺失年份、摘要或 DOI 保持空值，并通过 metadataMissing 暴露，不使用固定年份或相关度填补。

关系图也区分语义：参考文献和 citing papers 使用有向 CITES，OpenAlex related works 使用无向 RELATED，前端分别用箭头和虚线编码。该设计避免把“相关推荐”误解为真实引用关系。

### 3.2.2 部署、安全与可降级运行

系统通过 Docker Compose 启动 Web、API、PostgreSQL、Redis 和 Neo4j。Web 容器只承载静态页面与反向代理，模型和学术 API 密钥仅注入 API 容器；真实配置以只读方式挂载，密钥不进入前端构建产物。健康接口同时检查 API、PostgreSQL、Redis 与 Neo4j，任一核心依赖异常时返回 HTTP 503 和 overall=degraded。




图 7 容器化部署拓扑。外部学术 API、内部数据服务和用户流量在 API 层汇合，密钥与业务状态均与前端隔离。

表 2 关键故障与降级行为

| 故障                 | 系统行为                | 可信保证            |
|--------------------|---------------------|-----------------|
| LLM 未配置或输出异常       | 切换确定性规则规划器          | 查询仍可执行，降级原因留痕   |
| 单一学术 API 限流        | 全局限速、指数退避或使用另一来源    | 失败来源和 HTTP 尝试可见 |
| Cross Encoder 不可用  | 保留基础融合排序            | 不扩大为整次检索失败      |
| PostgreSQL 开发环境不可达 | 可切换本地 SQLite        | 仅用于开发，不伪装生产状态   |
| 核心依赖异常             | 健康接口返回 503/degraded | 部署编排据真实状态判断就绪   |

### 3.3 实验设计与结果

证据分层与防止口径混淆。实验不按开发时间叙述，而按要回答的问题分为两层：排序模块实验回答“哪些检索和重排组件改善首位相关性”，输出策略实验回答“在冻结候选上，按分数结构调整返回数量是否优于固定 Top-K”。两层实验的数据划分和结论边界不同，不能拼接成一个完整系统总分。




图 8 分层实验协议。排序模块在固定 200 条样本上比较，输出策略在 100 条开发集上选规则并在 100 条独立测试集上评估。

数据来自 ScholarGym 本地镜像，从 2,536 条查询中按来源分层抽取 200 条，其中 156 条来自 PaSa AutoScholar、4 条来自 PaSa RealScholar、40 条来自 LitSearch；论文库包含 570,206 篇记录，随机种子固定为 2026。Gold 匹配依次使用 arXiv ID、DOI、数

据源 ID 和规范化标题。主指标为逐查询 F1 的算术平均，同时报告 Precision、Recall、MAP、nDCG、置信区间、时延和调用成本。

排序模块消融。所有比较使用相同 200 条查询、论文快照、Top-100 候选上限和 Top-1 输出。标题偏置词法召回把标题权重设为 5、摘要为 1；等权词法召回把二者均设为 1；最终候选排序器在等权词法召回上增加 Top-20 LCER；多路 RRF 方案增加路由融合后使用相同精排。表 3 显示，标题和摘要等权带来最大绝对增益，局部精排进一步改善 F1；额外多路 RRF 未继续提升，因此被保留为消融证据而非最终路径。

表 3 排序模块消融结果（固定分层样本  $n = 200$ ）

| 方法            | P@1           | R@1           | F1@1          | F1 95% CI               | 延时/ms        |
|---------------|---------------|---------------|---------------|-------------------------|--------------|
| 标题偏置词法召回      | 0.2250        | 0.1745        | 0.1862        | [0.1377, 0.2371]        | —            |
| 等权词法召回        | 0.3000        | 0.2301        | 0.2466        | [0.1928, 0.3015]        | 1022.3       |
| 等权词法召回 + LCER | <b>0.3300</b> | <b>0.2454</b> | <b>0.2649</b> | <b>[0.2092, 0.3226]</b> | <b>741.7</b> |
| 多路 RRF + LCER | 0.3200        | 0.2389        | 0.2562        | [0.1982, 0.3132]        | 905.0        |

等权词法召回与 LCER 相比等权词法召回的 F1 绝对增量为 0.0183，相对增幅约 7.4%。200 条查询全部完成且无失败，平均精排耗时 285.3 ms，API 调用、LLM 调用和 Token 消耗均为 0。配对 bootstrap 差值区间为  $[-0.0017, 0.0408]$ ，跨越 0。因此，实验支持局部精排存在正向趋势，不支持统计显著领先的强结论。

自适应输出策略对照。排序候选冻结后，200 条查询按来源和稳定哈希拆为 100 条开发集与 100 条测试集，两侧均包含 78 条 AutoScholar、2 条 RealScholar 和 20 条 LitSearch。CARS 只在开发集搜索 8,064 组候选规则；测试 Gold 在规则确定前不参与阈值或最大返回数选择。固定 Top-1、Top-2、Top-3、Top-5 与 CARS 使用完全相同的测试查询和候选排序。

表 4 自适应输出策略独立测试结果 ( $n = 100$ , 候选冻结)

| 方法          | P             | R             | Macro<br>F1   | F1 95% CI                   | 平均返回<br>数   |
|-------------|---------------|---------------|---------------|-----------------------------|-------------|
| 固定 Top-1    | 0.3300        | 0.2241        | 0.2475        | [0.1715,<br>0.3255]         | 1.00        |
| 固定 Top-2    | 0.1900        | 0.2537        | 0.1986        | [0.1424,<br>0.2537]         | 2.00        |
| 固定 Top-3    | 0.1400        | 0.2697        | 0.1665        | [0.1219,<br>0.2105]         | 3.00        |
| 固定 Top-5    | 0.0960        | 0.2926        | 0.1304        | [0.0991,<br>0.1627]         | 5.00        |
| <b>CARS</b> | <b>0.3350</b> | <b>0.2374</b> | <b>0.2571</b> | <b>[0.1812,<br/>0.3350]</b> | <b>1.07</b> |

固定增加  $K$  虽提高 Recall, 却持续降低 Precision 和 Macro F1, 说明“返回更多论文”不能自动构成有效创新。CARS 仅在 7% 的测试查询上增加第二篇, F1 比固定 Top-1 高 0.0097。配对差值区间  $[0.0000, 0.0267]$  包含 0, 现有样本只支持轻量门控可能改善精确率-召回率平衡的初步判断。




图 9 消融与对照结果。a, 标题摘要等权与局部语义精排逐步改善 F1, 多路 RRF 未优于最终候选排序器; b, 固定扩大结果集导致 F1 下降, CARS 以接近 Top-1 的返回规模取得最高测试 F1。

真实查询案例与失败边界。在 AutoScholarQuery\_test\_548 中, 查询要求寻找借助 Transformer 提高低纹理区域准确率的半稠密匹配方法, Gold Set 包含 LoFTR、ASpanFormer 与 MatchFormer。等权词法排序首位是未命中 Gold 的 *Multi-Spectral Visual Odometry without Explicit Stereo Matching*; LCER 在相同候选池中把 LoFTR 提升至第

一位、MatchFormer 提升至第二位，使该查询 F1@1 从 0 提高到 0.5。该案例只证明候选池内部的语义重排能够纠正词法误序，不能代表所有学科或在线检索条件。

主要失败边界包括：摘要缺失使覆盖诊断与语义精排证据不足；同义表达可能不被词项覆盖规则识别；RealScholar 在 200 条样本中仅有 4 条，来源分组估计不稳定；在线学术 API 的限流、更新与排序漂移尚未进入冻结对照；CARS 测试集只有 100 条且阈值未在跨语料上复验。这些边界直接限制可宣称的泛化范围。

### 3.4 作品完整性与展示闭环

可运行系统。项目已开源，[代码仓库](#)提供 npm CLI、Docker Compose、配置模板和启动脚本。用户可通过终端引导配置 API Key，未配置 LLM 时仍能使用规则规划器完成基本检索。当前回归证据见表 5。

表 5 工程验证与复现入口

| 对象      | 结果                 | 覆盖内容                            | 复现入口                |
|---------|--------------------|---------------------------------|---------------------|
| 后端自动化测试 | 48/48 通过           | 来源、缺失元数据、约束、补检、精排、CARS、缓存、限流与指标 | tests/              |
| CLI 与打包 | 8/8; 300.4 kB      | 初始化、端口、密钥、重启与发布文件白名单            | npm test、pack:check |
| 前端生产构建  | 类型检查与构建通过          | Vue/TypeScript 类型和静态产物          | npm run build       |
| 排序模块评测  | 200/200 完成         | 固定语料、候选、F1/MAP/nDCG、成本与时延       | 离线评测脚本              |
| 自适应选择评测 | 100 dev + 100 test | 固定 Top-K、CARS、阈值隔离和配对 bootstrap | 选择策略脚本              |

交互与结构化输出。用户输入复杂问题后，结果页依次展示查询计划、首轮召回、覆盖诊断、补检、精排和结果输出。每篇论文展示题名、作者、Venue、年份、摘要、来源、推荐理由和开放获取入口；进入详情页可查看相关论文和分型关系图，并保存到收藏或课题库。下列界面截图是工程实现证据，不作为检索效果证明。






图 10 自然语言检索首页。示例提示帮助用户表达主题、时间、方法和成果约束。




图 11 检索结果页。查询计划、覆盖状态、运行轨迹和带来源证据的论文候选在同一页面呈现。



图 12 论文详情页。页面汇总元数据、摘要、开放获取入口、相关论文和关系信息。

3.5 应用价值与科研服务前景

科研应用定位。通用学术搜索平台擅长关键词或引用网络检索，通用大模型擅长语言交互，但二者通常不同时提供复合约束编译、预算可审计的自主检索、来源级故障传播和科研工作流沉淀。ESASR 不替代 OpenAlex、Semantic Scholar 等大型学术索引，而是作为连接公开学术数据源与科研用户的可控检索编排层，为复杂查询提供可复现、可降级和可追踪的证据组织能力。

表 6 科研服务场景与技术验收指标

| 科研场景                | 系统支持                  | 主要验收指标                   |
|---------------------|-----------------------|--------------------------|
| 复杂选题与开题调研           | 复合约束编译、多源召回和证据覆盖诊断    | 有效论文率、硬约束违反率和任务完成时间      |
| Related Work 与跨学科检索 | 可解释排序、局部语义精排和来源追踪     | Top-K 检索质量、来源完整性和重复结果比例  |
| 课题组证据管理             | 共享课题库、检索轨迹和论文关系组织     | 结果可复现率、检索记录完整性和用户可用性     |
| 科研信息服务              | 检索编排 API、统一身份与结构化结果接口 | 并发能力、p95 时延、故障恢复时间和数据合规性 |

科研服务与技术验收。后续应用验证应优先选择不同学科的高校课题组，在真实开题调研和 Related Work 任务中记录任务完成时间、有效论文率、重复检索率、约束遗漏率与用户修正次数。只有当系统在跨学科任务中保持稳定的检索质量、时延和故障恢复能力，才能进一步扩大科研服务范围。

### 3.6 风险、合规与下一步验证

风险控制。学术 API 限流通过全局速率控制、指数退避、缓存和多源互补缓解；LLM 异常通过统一模式校验与规则规划降级；精排资源不足通过 Top-N 限制和基础排序回退；缺失元数据通过多源补全与显式缺失标记处理；公网部署前必须限制 CORS、轮换 JWT 和数据库密钥、启用 HTTPS。系统不抓取未授权全文，也不把 AI 生成内容冒充论文原文。

优先验证清单。后续工作按评审风险排序。第一，冻结更大的跨学科测试集，在预注册 CARS 阈值下复验并报告效应区间。第二，在相同 API 任务数、相同时间窗口和冻结响应下，比较无补检、固定二轮检索与 EGRR，验证其 F1 与单位真阳性检索开销。第三，补充 CQC 的槽位 F1、硬约束违反率和分类型错误分析。第四，开展并发、限流、断网和依赖故障注入，报告 p50/p95 时延与恢复时间。第五，完成跨学科真实科研用户测试，记录任务效率、结果修正次数和来源核验行为。只有通过这些检验，相应能力才进入强效果、稳定性或泛化性主张。

### 3.7 计划和分工

团队按职责组织实施：项目统筹负责需求、进度与实验口径；检索算法负责查询编译、多源召回、覆盖诊断、精排与评测；后端负责接口、缓存、数据库和部署；前端负责交互、可视化和状态恢复；测试与材料负责人负责标注、回归、用户反馈和交付归档。成员可兼任多个角色，但每项实验和里程碑均需明确验收人。

#### 3.7.1 交付与复现

项目根目录执行启动脚本可构建并启动服务；本地 Cross Encoder 通过精排开关启用。交付保留环境变量示例与配置模板，真实密钥不进入代码仓库。实验目录保存 Gold、逐查询预测、指标、置信区间、开发/测试拆分和阈值搜索记录，可依据数据哈希、随机种子和模型名称复跑。建议验收顺序为：运行后端与 CLI 测试、构建前端、复跑两层离线实验、启动五类服务、执行复杂查询并检查轨迹与来源、模拟组件故障、最后归档代码提交、依赖清单、配置哈希和原始响应。

完整的探索顺序、负结果、技术瓶颈和解决闭环已从主报告分离，见配套附加材料《技术迭代与问题解决记录》。该材料用于过程审计，不改变本报告对最终方案与证据边界的定义。

## 4 参考资料

1. 中国研究生创新实践系列大赛，第八届中国研究生人工智能创新大赛赛题揭榜公告，赛题“科研场景下复杂学术查询的智能论文搜索与推荐”，2026。
2. He Y., Huang G., Feng P., et al. PaSa: An LLM Agent for Comprehensive Academic Paper Search. ACL, 2025, pp. 11663–11679.
3. Ajith A., Xia M., Chevalier A., et al. LitSearch: A Retrieval Benchmark for Scientific Literature Search. EMNLP, 2024, pp. 15068–15083.
4. Jeong S., Baek J., Cho S., et al. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. NAACL, 2024.
5. Asai A., Wu Z., Wang Y., et al. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. ICLR, 2024.
6. Kang S., Zhang Y., Jiang P., et al. Taxonomy-guided Semantic Indexing for Academic Paper Search. EMNLP, 2024.
7. Cormack G. V., Clarke C. L. A., Büttcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. SIGIR, 2009.
8. Nogueira R., Cho K. Passage Re-ranking with BERT. arXiv:1901.04085, 2019.
9. OpenAlex Documentation. <https://docs.openalex.org/>.
10. Semantic Scholar Academic Graph API Documentation. <https://api.semanticscholar.org/api-docs/>.
11. FastAPI Documentation; Vue.js Documentation; Docker Compose Documentation.